

Prédiction de DIFF

Comparaison de méthodes de classification supervisée


Régression logistique · Arbre de décision · KNN · SVM à noyaux

Équipe numéro 1


ALFONSI Donia · BEKAKRIA Ahmed · MARCHAL Florient · RAYID Ahamada Rachid

Contexte & jeu de données

- Objectif : prédire la variable binaire DIFF (0 / 1) à partir de 7 variables explicatives
- TOF, AGE, R7, R8, R17, R22, R32
- 299 observations en apprentissage
- Classes bien équilibrées : 149 (DIFF=0) vs 150 (DIFF=1)



Exploration des données — corrélations



Ce qu'on observe

- R32 est la variable la plus corrélée à DIFF ($\rho \approx 0.7$)
- R17 est corrélée négativement à DIFF
- Les autres variables apportent une information plus faible prise isolément

Méthodes comparées



Régression
logistique



Arbre de
décision




k plus proches
voisins



SVM à noyaux

Les 4 méthodes sont évaluées avec le même critère : l'AUC (aire sous la courbe ROC) sur le jeu de vérification.

Régression logistique — choix de C





C = 0.01

Meilleur paramètre
(validation croisée)


0.906

AUC moyenne
en validation croisée


R32, la variable la plus discriminante



Régression logistique — courbes ROC




AUC = 0.906 (validation croisée)



AUC = 0.838 (jeu de vérification)


Arbre de décision — arbre CART retenu

Arbre CART retenu - Profondeur maximale 5



R32 est utilisée dès la racine de l'arbre — cohérent avec la matrice de corrélation vue plus tôt.


Performance de l'arbre selon sa profondeur
Choix de la profondeur maximale




Profondeur 5

AUC = 0.8063
(validation croisée)





Arbre de decision— courbe ROC



KNN— courbe ROC



SVM — comparaison des 4 noyaux



Cosinus

Meilleur noyau SVM
AUC = 0.845

0.837 – 0.845

AUC des 4 noyaux
(très proches)

Conclusion & perspectives

- Toutes les méthodes testées atteignent des performances proches ($AUC \approx 0.84$ sur le jeu de vérification)
- Le noyau cosinus arrive légèrement en tête parmi les SVM ($AUC = 0.845$)
- Perspectives : comparer avec l'arbre de décision et le KNN, tester le rééquilibrage / d'autres jeux d'hyperparamètres, valider sur le jeu de test privé